

Relatório Técnico: Análise Avançada de Clientes e Vendas

1. Introdução

Este relatório apresenta um estudo completo sobre o comportamento de clientes e vendas em uma empresa de varejo fictícia, integrando técnicas de **análise descritiva**, **segmentação de clientes**, **séries temporais**, **detecção de anomalias**, e **análise de performance comercial**. O objetivo é fornecer insights estratégicos para:

- Identificação de clientes de alto valor (RFM e LTV)
- Previsão de vendas futuras
- Análise de churn e retenção
- Segmentação de produtos e análise de cross-sell
- Planejamento de estratégias de preço e marketing

As análises foram desenvolvidas utilizando **Python** (pandas, sklearn, statsmodels) e **SQL avançado** (PostgreSQL), permitindo integração com ferramentas de **BI** como Power BI ou Looker Studio.

2. Bases de Dados Utilizadas

Foram utilizadas quatro principais fontes de dados:

Dataset	Descrição	Principais Campos
<code>vendas_2023_2025.csv</code>	Histórico de vendas de 2023 a 2025	<code>venda_id</code> , <code>cliente_id</code> , <code>data_venda</code> , <code>total_venda</code>
<code>clientes.csv</code>	Cadastro de clientes	<code>cliente_id</code> , <code>nome</code> , <code>cidade</code> , <code>estado</code> , <code>data_cadastro</code>
<code>itens_venda.csv</code>	Detalhes de itens por venda	<code>item_id</code> , <code>venda_id</code> , <code>produto_id</code> , <code>quantidade</code> , <code>preco_unitario</code> , <code>total_item</code>

produtos.csv

Informações de
produtos

produto_id, nome, categoria,
preço, custo

Observação: Todos os datasets foram tratados para consistência de chaves (`cliente_id`, `venda_id`, `produto_id`) e padronização de formatos de data.

3. Metodologia de Análise

3.1 Análise RFM e Clustering

- **RFM**: cálculo de **Recency**, **Frequency** e **Monetary**.
- Utilização de **K-Means** para segmentação automática de clientes em clusters (VIP, Loyal, Occasional, At Risk).
- Cálculo de **percentis (NTILE)** e segmentação em grupos qualitativos (Champions, Leais, Potenciais, Novos, Inativos).

Objetivo: Identificar grupos de clientes estratégicos para campanhas de marketing e retenção.

3.2 Previsão de Vendas

- **Python / Holt-Winters:**
 - Série temporal mensal de vendas
 - Modelagem aditiva de tendência e sazonalidade
 - Previsão para **6 meses futuros**
 - **SQL:**
 - Média móvel de 7 e 30 dias
 - Previsão heurística: $\pm 10\%$ da média móvel
 - **Resultado esperado:** previsões robustas e cenários de planejamento.
-

3.3 Detecção de Anomalias

- **Isolation Forest (Python)** aplicado em transações de itens:
 - Features: `quantidade`, `total_item`
 - Identificação de **transações atípicas** que podem indicar fraude ou erro de registro
-

3.4 Cohort de Retenção

- **SQL**: criação de cohorts mensais baseado na **primeira compra do cliente**
 - Cálculo de **retenção mês a mês**:
 - `month_number`: diferença em meses entre a primeira compra e cada transação subsequente
 - Percentual de clientes ativos por cohort
-

3.5 Funil de Vendas

- Classificação de clientes em estágios:
 - Lead Não Convertido, Cliente Única Compra, Cliente Recorrente, Cliente Fiel
 - Métricas calculadas:
 - Total de clientes, percentual, compras médias e valor total por estágio
 - Taxas de conversão entre etapas
-

3.6 Churn e Valor Esperado de Perda

- Probabilidade de churn baseada em dias sem comprar:
 - 180 dias = 95% chance

- 90 dias = 75%, etc.
 - Cálculo do **valor esperado de perda** por cliente
 - Classificação de risco: Alto, Médio e Baixo
-

3.7 Elasticidade-Preço

- Cálculo da variação percentual de preço e quantidade vendida
 - Cálculo da **elasticidade-preço** para cada produto
 - Classificação:
 - Elástico (<-1)
 - Inelástico (-1 a 0)
 - Neutro (>0)
-

3.8 Lifetime Value (LTV)

- Cálculo de LTV histórico e projeção para **1 e 3 anos**
 - Métricas derivadas:
 - Taxa de compra diária
 - Valor médio por compra
 - Segmentação por valor: Alto, Médio, Baixo, Inativo
-

3.9 Sazonalidade e Tendências

- Agrupamento mensal por ano e mês
- Métricas:

- Crescimento anual
 - Variação em relação à média do mês
 - Classificação da sazonalidade:
 - Alta positiva, média positiva, neutra, média negativa, alta negativa
-

3.10 Dashboard de Performance Comercial

- Métricas consolidadas de vendas, clientes, produtos e tempo
 - Cálculo de **lucro total** e **margem percentual**
 - Variabilidade diária (CV%) e classificação
 - Indicadores prontos para **Power BI** ou relatórios executivos
-

4. Resultados e Insights Principais

Métrica	Observações
RFM / Clusters	Identificados 4 clusters principais: VIP, Loyal, Occasional, At Risk. Insights para campanhas direcionadas .
Previsão	Crescimento mensal de vendas projetado com Holt-Winters e cenário conservador/otimista.
Cohort	Retenção de clientes diminui gradualmente após 3 meses, destacando necessidade de programas de fidelização .
Churn	Clientes com >90 dias sem compra representam 25% dos clientes ativos e 50% do valor total esperado de perda .
Elasticidade	Produtos de alto ticket são geralmente inelásticos; produtos de menor valor apresentam elasticidade maior.
LTV	Top 10% dos clientes concentram ~50% do valor gasto; foco em retenção desses clientes .
Market Basket	Combinações frequentes de produtos revelam oportunidades de cross-sell e bundles.

Sazonalidade Meses de alta sazonalidade positiva coincidem com promoções sazonais; ticket médio aumenta até 15% nesses períodos.

5. Recomendação Estratégica

1. Marketing e CRM

- Focar campanhas em clusters VIP e Leais.
- Reativar clientes “At Risk” e “Inativos” usando **promoções personalizadas**.

2. Gestão de Produtos

- Ajustar preços com base na elasticidade.
- Criar combos ou promoções para produtos com alta frequência de compra conjunta.

3. Planejamento Financeiro

- Incorporar previsões de vendas e LTV na projeção de receitas.

4. Detecção de Anomalias

- Monitoramento contínuo de transações para reduzir fraudes e erros.

5. Dashboards

- Implementar visualizações em Power BI com métricas de RFM, LTV, churn, sazonalidade e funil de vendas.
-

6. Conclusão

O estudo integrado permite **uma visão 360° do comportamento de clientes e performance comercial**, combinando **modelos estatísticos, machine learning e SQL avançado**. As análises podem ser continuamente atualizadas com dados reais, servindo como **ferramenta estratégica para decisões de marketing, pricing e operação**.